Data Mining

Supervised Machine Learning

Dr. Hanna Köpcke

Wintersemester 2020

Abteilung Datenbanken, Universität Leipzig
http://dbs.uni-leipzig.de

Übersicht

Hochdimensionale Daten

- Clustering
- Dimensions-reduktion
- Empfehlungs-systeme
- Assoziations-regeln
- Locality Sensitive Hashing
- **Supervised ML**

Graphdaten

- Community Detection
- PageRank
- Web Spam

Datenströme

- Windowing
- Filtern
- Momente
- Web Advertising

Inhaltsverzeichnis

Supervised Learning

- Daten zu einem Paar $(\boldsymbol{x}, y)$
  - $\boldsymbol{x}$ ist ein Vektor aus Merkmalen (Features):
    - verschiedene Datentypen möglich
    - Beispiel: (Age, Male, Class)
  - y ist eine Bezeichnung (Label),
    - eine reelle Zahl oder eine Kategorie (Klasse)
    - Beispiel: Survived

Age	Male	Class	Survived
Child	True	1	Yes
Adult	True	2	No
Adult	False	1	Yes
Child	True	3	No
…	…	…	…

- **Ziel**: Auffinden einer Funktion (Modell) f mit

$$y = f(\boldsymbol{x})$$

- Vielzahl an Funktionen möglich
- Bewertung und Auswahl der Funktion über Daten
  - Aufteilung in Trainings- und Testdaten (z.B. 80% vs. 20%)
  - Schätzen der Funktion über Trainingsdaten: *Fehler möglichst gering*
  - Bewerten der Funktion an Testdaten: *Fehler möglichst gering*

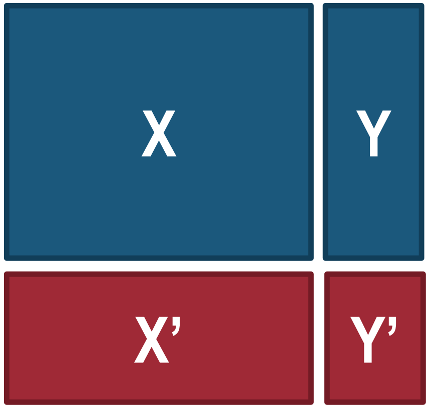

Trainings-/
Testdaten

Methoden des Supervised ML

Bewährte Methoden (Ausschnitt)
Lineare Regression
Logistische Regression
Linear Discriminant Analysis
K-Nearest Neighbors
Naïve Bayes
Entscheidungsbäume
Support Vector Machines
Neuronale Netze

- Generelles Problem bei hochdimensionalen Daten: **Overfitting** (Funktion passt sich den zufälligen Fehlern an)
- Lösung z.B.
  - Dimensionsreduktion über PCA/SVD oder Clustering
  - Regularisierung (Ridge, Lasso)
  - Informationskriterien, z.B. AIC, BIC, DIC, WAIC, …

Inhaltsverzeichnis

Entscheidungsbäume

- Variable Y: numerisch (Regression) oder kategorial (Klassifikation)
- Vorhersage von Y durch X über eine Baumstruktur
  - Folge den Ästen des Baums entsprechend den Werten von X
  - Vorhersagewert für Y an den Blattknoten

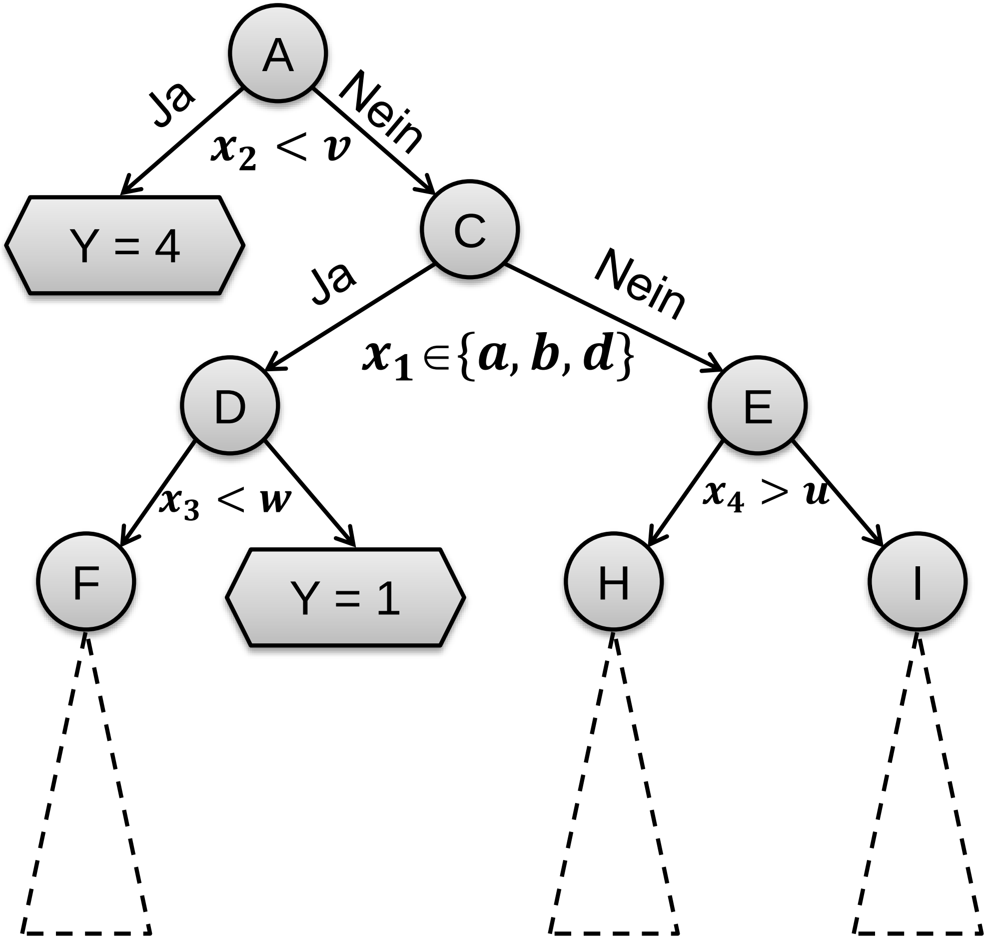

Erstellen eines Entscheidungsbaums (Regression)

Ziel: Aufteilung der Variaben aus X in Regionen $R_1, R_2, \dots, R_J$, so dass

$$\sum_{j=1}^{J} \sum_{i \in R_j} \left(y_i - \widehat{y_{R_j}}\right)^2$$

minimiert wird ($\widehat{y_{R_j}}$ bezeichnet den Vorhersagewert der Region R_j).

- Vorhersagewert ist der *Mittelwert* der Datenpunkte der Region

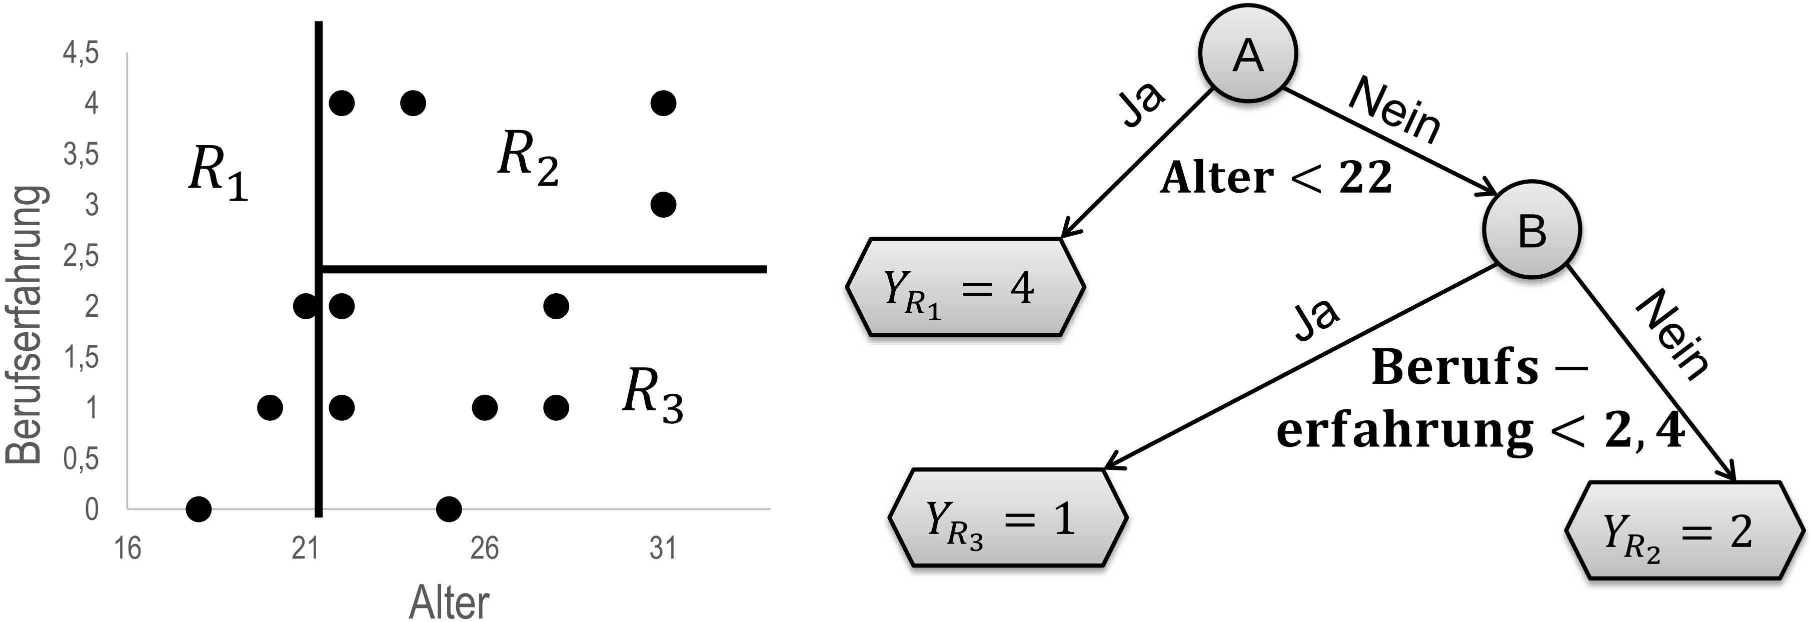

Erstellen eines Entscheidungsbaums (Regression)

Ziel: Aufteilung der Variaben aus X in Regionen $R_1, R_2, \ldots, R_J$, so dass

$$\sum_{j=1}^{J} \sum_{i \in R_j} \left(y_i - \widehat{y_{R_j}} \right)^2$$

minimiert wird ($\widehat{y_{R_j}}$ bezeichnet den Vorhersagewert der Region R_j).

- Vorhersagewert ist der *Mittelwert* der Datenpunkte der Region
- **Problem**: zu viele mögliche Aufteilungen in J Regionen
- Ausweg: **Recursive Binary Splitting**
  - Wiederholte Auswahl einer Variable X_j und eines Schwellenwerts s, so dass die beiden Regionen $R_1(j,s) = \{x | x_j < s\}$ und $R_2(j,s) = \{x | x_j \geq s\}$ die folgende Summe minimieren:

$$\sum_{i: x_i \in R_1(j,s)} \left(y_i - \widehat{y_{R_1}} \right)^2 + \sum_{i: x_i \in R_2(j,s)} \left(y_i - \widehat{y_{R_2}} \right)^2$$

  - Stopp, falls z.B. in jede Region weniger als 5 Datenpunkte fallen

Entscheidungsbaum für Klassifikation

- Vorhersagewert ist der *häufigste Wert* der Datenpunkte einer Region
- Fehlermaß: z.B. **Entropie**

$$\boldsymbol{H}(Y) = - \sum_{y \in \text{Domäne von } Y} p_y \log_2 p_y$$

- Der Wert p_y gibt die Wahrscheinlichkeit der Ausprägung $Y = y$
  - Hohe Entropie: gleichverteiltes Y
  - Niedrige Entropie: ungleiche Verteilung

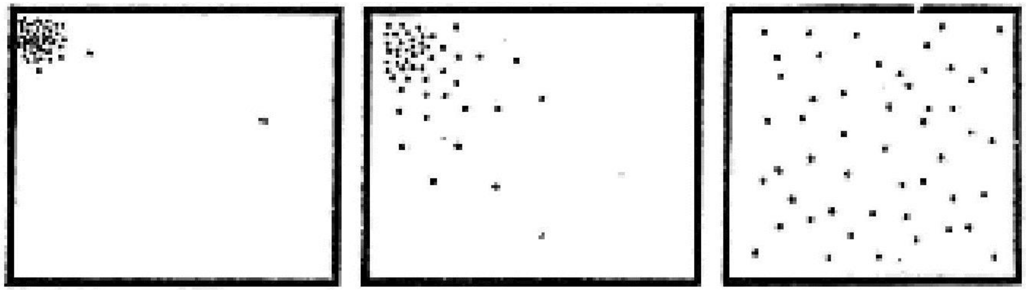

Niedrige Entropie **Hohe Entropie**

Entropie: Beispiel

- $\boldsymbol{X}$: Abschluss
- $\boldsymbol{Y}$: mag den Film “Casablanca”
- Schätzen der Wahrscheinlichkeiten über relative Häufigkeiten
  - $P(Y = Ja) = \frac{3}{8}, P(Y = Nein) = \frac{5}{8}$
  - $P(Y = Ja|X = Mathe) = \frac{1}{4}$
  - $P(Y = Nein|X = Mathe) = \frac{3}{4}$

X	Y
Mathe	Ja
Geschichte	Nein
Informatik	Ja
Mathe	Nein
Mathe	Nein
Informatik	Ja
Mathe	Nein
Geschichte	Nein

- Entropie:

$$H(Y) = -\frac{3}{8}\log_2\frac{3}{8} - \frac{5}{8}\log_2\frac{5}{8} \approx 0.95$$

- Spezifische bedingte Entropie:

$$H(Y|X = Mathe) = -\frac{1}{4}\log\frac{1}{4} - \frac{3}{4}\log\frac{3}{4} \approx 0.81$$

Entropie: Beispiel

- Bedingte Entropie:

$$H(Y|X) = \sum_{x \in O_X} P(X = x) H(Y|X = x)$$

x	$P(X = x)$	$H(Y|X = x)$
Mathe	$\frac{1}{2}$	0.81
Geschichte	$\frac{1}{4}$	0
Informatik	$\frac{1}{4}$	0

X	Y
Mathe	Ja
Geschichte	Nein
Informatik	Ja
Mathe	Nein
Mathe	Nein
Informatik	Ja
Mathe	Nein
Geschichte	Nein

$$H(Y|X) = \frac{1}{2} \cdot 0.81 + \frac{1}{4} \cdot 0 + \frac{1}{4} \cdot 0 = 0.4$$

- **Ziel:** Auswahl des Attributs X mit niedrigstem $H(Y|X)$

Beste Aufteilung eines Knotens

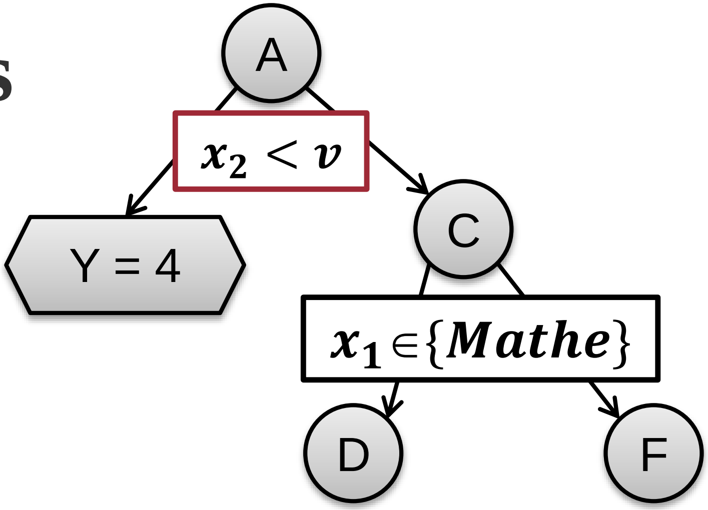

- Anschließend
  - X ist numerisch: Auswahl des Schwellenwertes
  - X ist kategorisch: Auswahl von Kategorien
- Beispiel:
  - Aufteilung: $X = Mathe$ vs. $X \neq Mathe$
    - $H(Y|X = Mathe) = 0.81$ und $H(Y|X \neq Mathe) = 1$
    - Spezifische bedingte Entropie gewichtet nach der Anzahl der Einträge pro Kindsknoten:
      $$\frac{1}{2} \cdot H(Y | X = Mathe) + \frac{1}{2} H(Y|X \neq Mathe) = 0.9$$
  - **Aufteilung: $X = Informatik$ vs. $X \neq Informatik$**
    - $H(Y|X = Informatik) = 0$ und $H(Y|X \neq Informatik) = 0.65$
    - $\frac{1}{4} \cdot H(Y|X = Informatik) + \frac{3}{4} H(Y|X \neq Informatik) = \mathbf{0.48}$
  - Aufteilung: $X = Geschichte$ vs. $X \neq Geschichte$
    - $H(Y|X = Geschichte) = 0$ und $H(Y|X \neq Geschichte) = 1$
    - $\frac{1}{4} \cdot H(Y|X = Geschichte) + \frac{3}{4} H(Y|X \neq Geschichte) = \frac{3}{4}$

Entscheidungsbäume

- Leicht zu verstehen, implementieren und interpretieren
- Parallelisierbar:
  - B. Panda, J. S. Herbach, S. Basu, and R. J. Bayardo. ***PLANET: Massively parallel learning of tree ensembles with MapReduce.*** In Proc. *VLDB* 2009.
  - J. Ye, J.-H. Chow, J. Chen, Z. Zheng. ***Stochastic Gradient Boosted Distributed Decision Trees***. In Proc. *CIKM* 2009.
- Sowohl für kategoriale als auch metrische Ergebnisvariable Y geeignet
- Problem: *Overfitting* (Überanpassung des Modells an die Daten)
  - Overfitting bei zu vielen Ebenen
  - Doch bei wenigen Ebenen können nur wenige Attribute verwendet werden und die Vorhersagegenauigkeit ist oft gering

Bagging und Random Forests

- Ausweg: Kombination mehrerer Entscheidungsbäume geringer Tiefe
- Über z.B. *Bagging*
  - Ziehen mehrerer Zufallsstichproben aus den Daten (mit Zurücklegen)
  - Ein Entscheidungsbaum geringer Tiefe pro Stichprobe
  - Mittelwert/häufigster Wert über alle Bäume ergibt Vorhersage
- *Random Forest*: Zusätzlich zum Bagging wird beim Lernen der Bäume an jedem Knoten nur eine kleine (zufällige) Auswahl der Attribute betrachtet

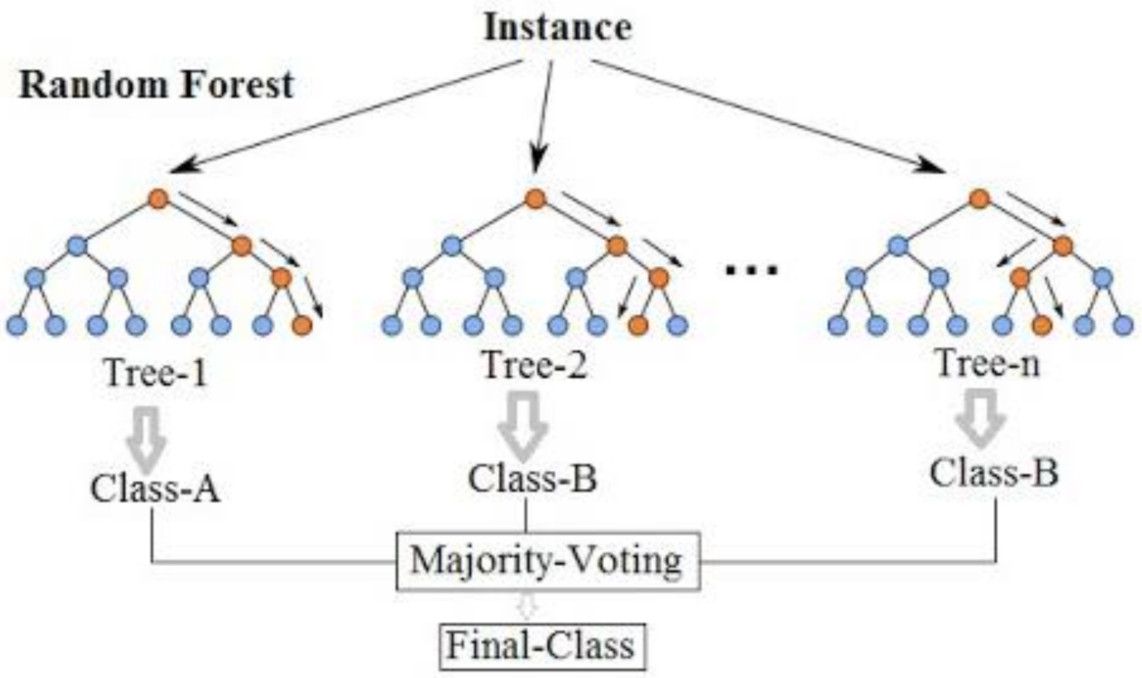

Inhaltsverzeichnis

- Einführung
- Entscheidungsbäume
- Support Vector Machines
- Neuronale Netze

Klassifizierung über Hyperebene

- Numerischer Merkmalsvektor $\boldsymbol{x} = (x_1, \dots x_n)$
- Binäre Variable $y \in \{-1, +1\}$

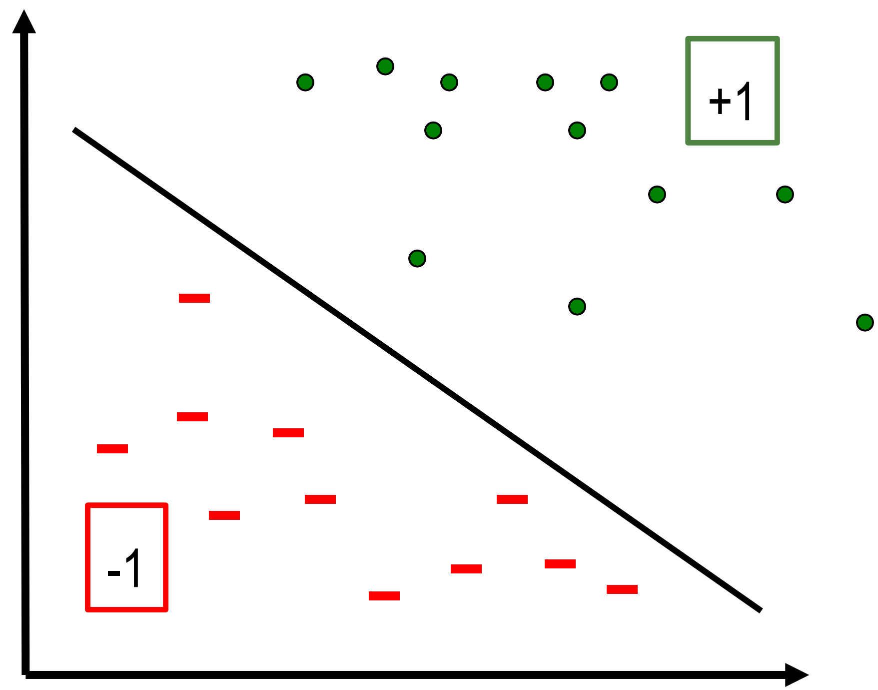

Klassifizierung über Hyperebene

- Numerischer Merkmalsvektor $\boldsymbol{x} = (x_1, \dots x_n)$
- Binäre Variable $y \in \{-1, +1\}$

- Eine Hyperebene des $\mathbb{R}^n$ teilt diesen Raum in 2 Bereiche
- Die Gewichte $\boldsymbol{w} = (w_0, w_1, \dots, w_n) \in \mathbb{R}^{n+1}$ beschreiben eine *Hyperebene H* über

$$H = \left\{ x \in \mathbb{R}^n | w_0 + \sum_{i=1}^{n} w_i \, x_i = 0 \right\}$$

- Klassifizierung über Hyperebene:

$$\hat{y} = +1, \text{ falls } w_0 + \sum_i w_i x_i > 0$$
$$\hat{y} = -1, \text{ falls } w_0 + \sum_i w_i x_i < 0$$

Klassifizierung über Hyperebene

Ziel: Finden der Parameter $\boldsymbol{w}$, so dass der Raum der Merkmalsvektoren in zwei Teile aufgespalten wird und Punkte mit dem gleichen Label auf der gleichen Seite sind

$$w_0 + \sum_{i=1}^{n} w_i \, x_i^{+} > 0$$

$$w_0 + \sum_{i=1}^{n} w_i \, x_i = 0$$

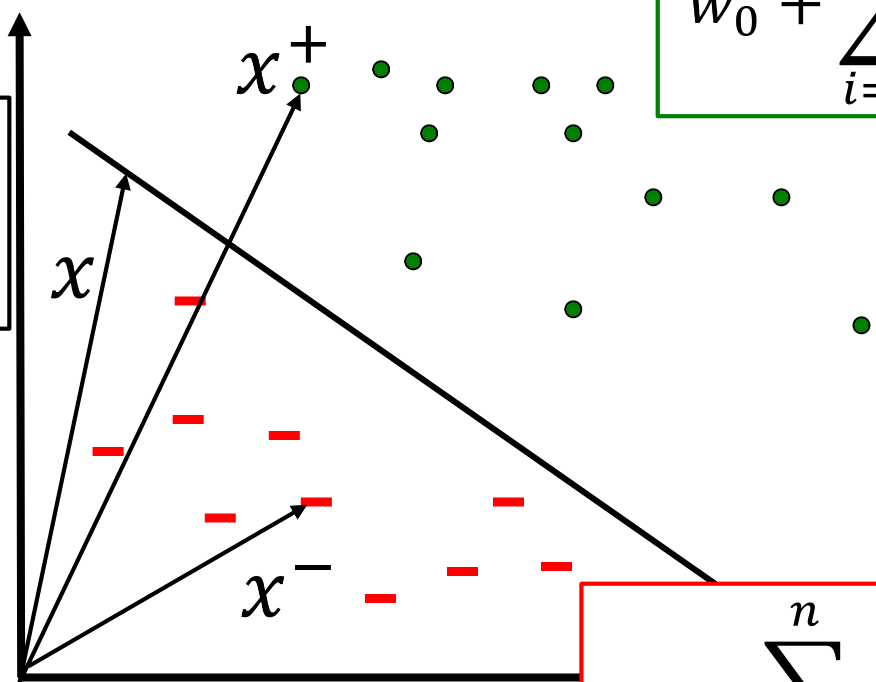

$$w_0 + \sum_{i=1}^{n} w_i \, x_i^{-} < 0$$

Auswahl der Hyperebene

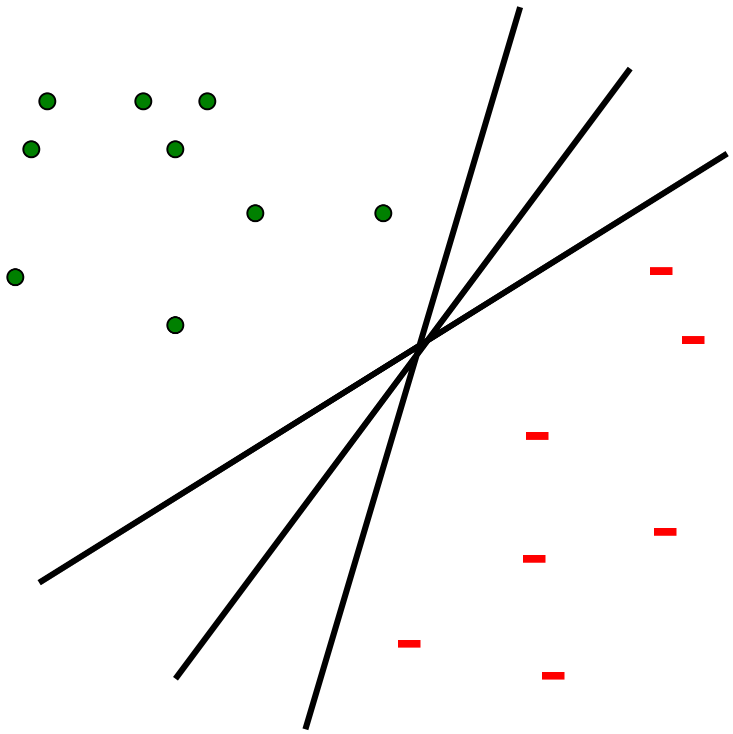

Welche Hyperebene ist die beste?

Maximal Margin Classifier

Verwendung der Hyperebene mit maximalen Abstand $\boldsymbol{\gamma}$ zu den Daten

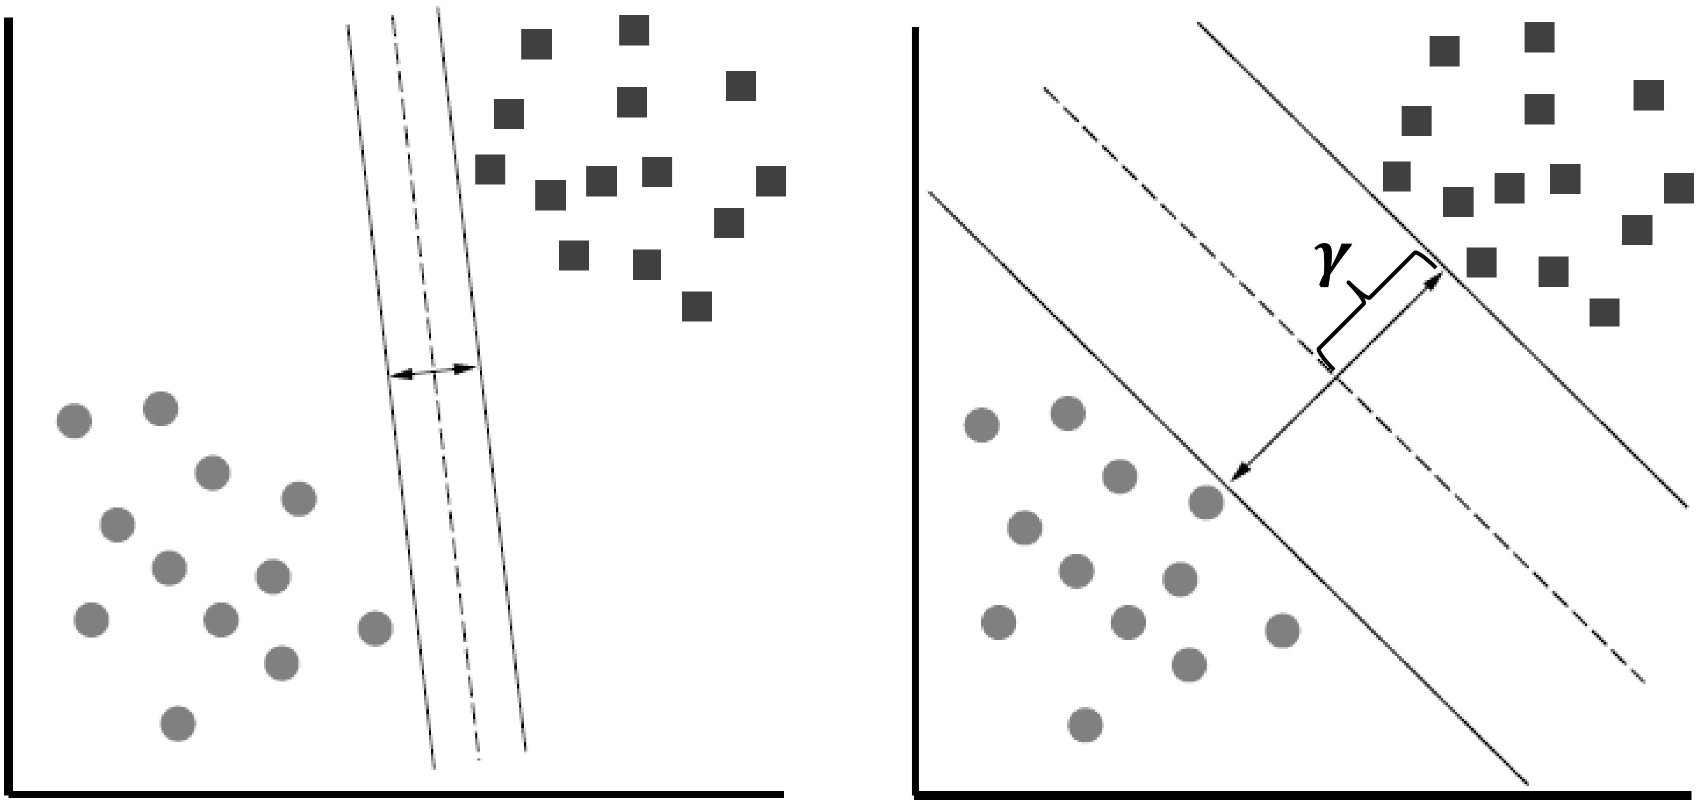

Maximal Margin Classifier

Ziel: Suche nach Gewichten $\boldsymbol{w} = (w_0, w_1, \ldots, w_n)$, so dass **1. der Rand (Margin) $\boldsymbol{\gamma}$ maximal** ist und 2. für alle Daten $(\boldsymbol{x}, y)$, gilt:

$$y\left(w_0 + \sum_{i=1}^{n} w_i\, x_i\right) \geq 1$$

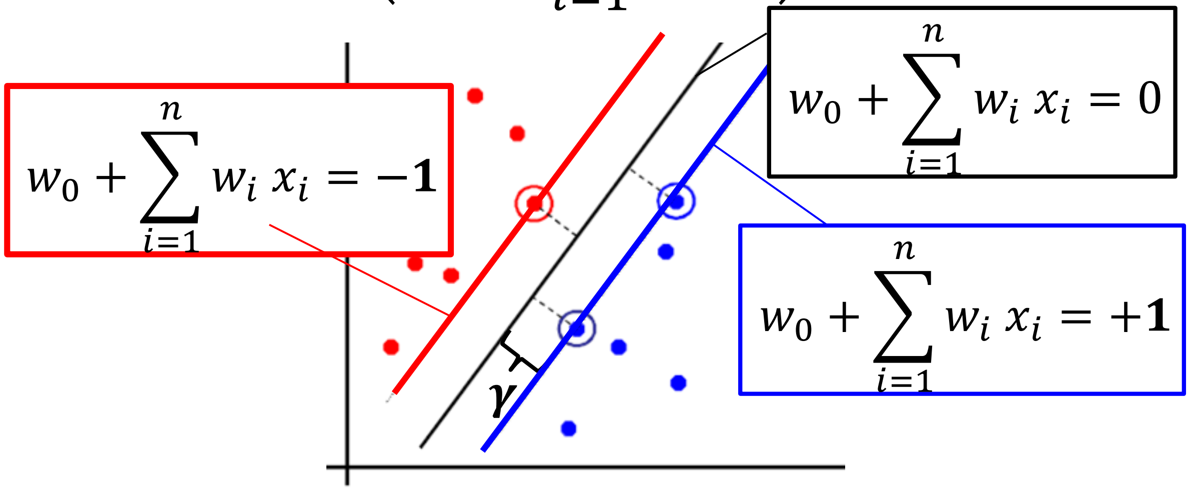

Sei $\mathbf{w}' = (w_1, \ldots, w_n)$. Für den Rand gilt: $\gamma = \frac{1}{|\boldsymbol{w}'|}$

γ ist maximal, wenn $\sqrt{\sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{w_i^2}}$ minimal ist.

Maximal Margin Classifier

Sei $\mathbf{w}' = (w_1, \dots, w_n)$. Für $\boldsymbol{x}^+$ gilt:

$$
\begin{aligned}
1 &= w_0 + \sum_{i=1}^{n} w_i \, x_i^+ \\
&= \mathrm{w}_0 + \mathbf{w}' \cdot \boldsymbol{x}^+ \\
&= w_0 + |\mathbf{w}'||\boldsymbol{v}'| \\
&= \mathrm{w}_0 + |\mathbf{w}'|(|\boldsymbol{v}| + \gamma) \\
&= \mathrm{w}_0 + |\boldsymbol{w}'||\boldsymbol{v}| + |\boldsymbol{w}'|\gamma \\
&= \mathrm{w}_0 + \boldsymbol{w}' \cdot \boldsymbol{x} + |\boldsymbol{w}'|\gamma \\
&= 0 + |\boldsymbol{w}'|\gamma
\end{aligned}
$$

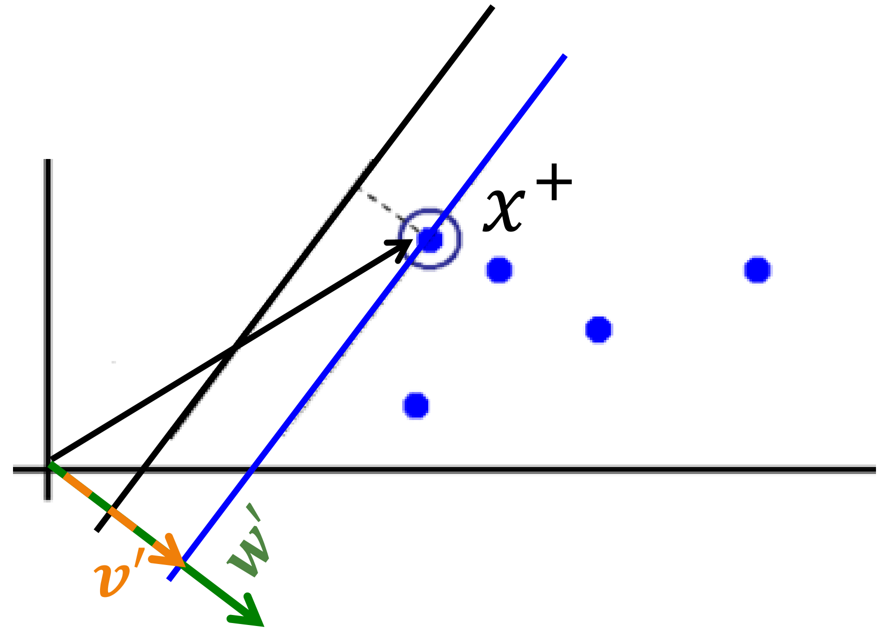

Orthogonale Projektion von x^+ auf w'

Also: $1 = |\boldsymbol{w}'|\gamma$

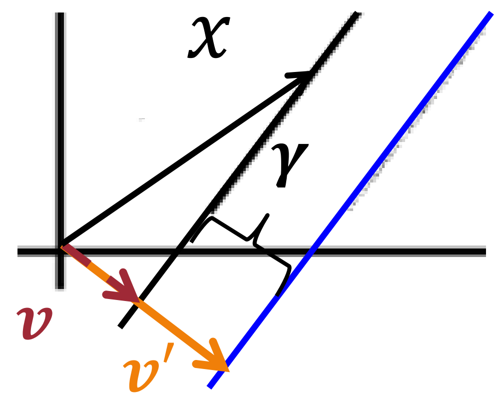

Rand γ ist maximal, wenn

$|\boldsymbol{w}'| = \sqrt{\sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{w}_{\mathbf{i}}^{\mathbf{2}}}$ minimal

Linear nicht trennbare Daten

- Falls Daten nicht linear trennbar, Einführung einer *Bestrafung* für falsche Zuordnungen:

$$\min_{\boldsymbol{w}} \sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{w_i^2} + \boldsymbol{C} \cdot (\#\ \textbf{falsche Zuordnungen})$$

- Optimaler Wert für den Parameter C kann über Testdaten ermittelt werden
  - $\boldsymbol{C}$ groß: wichtig ist die Trennung der Daten (soweit möglich)
  - $\boldsymbol{C}$ klein: wichtig ist ein großer Rand

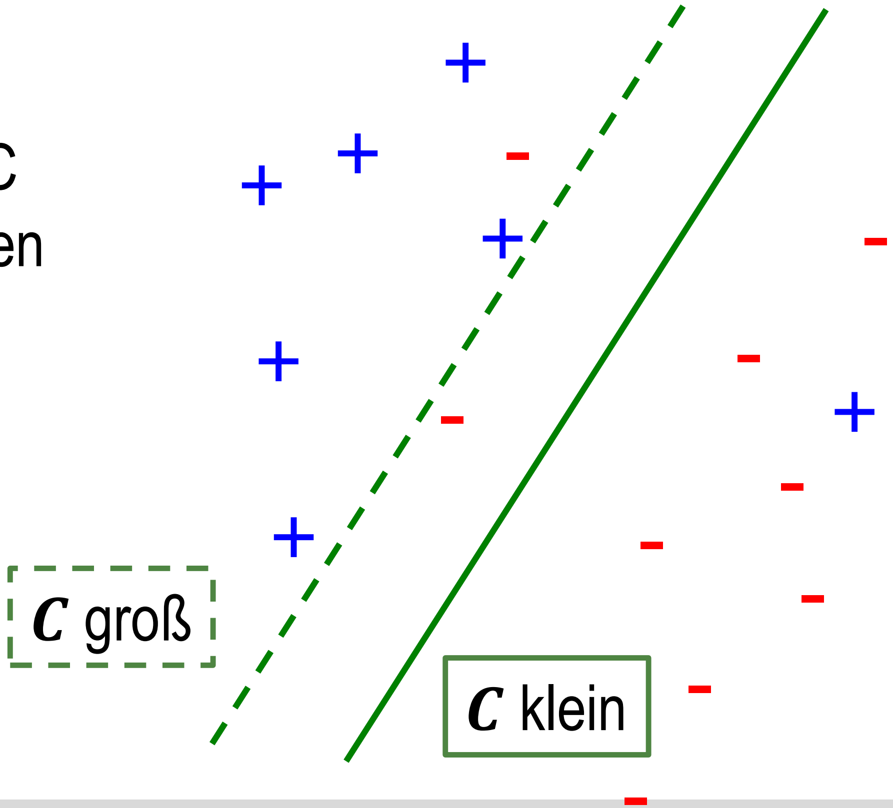

Linear nicht trennbare Daten

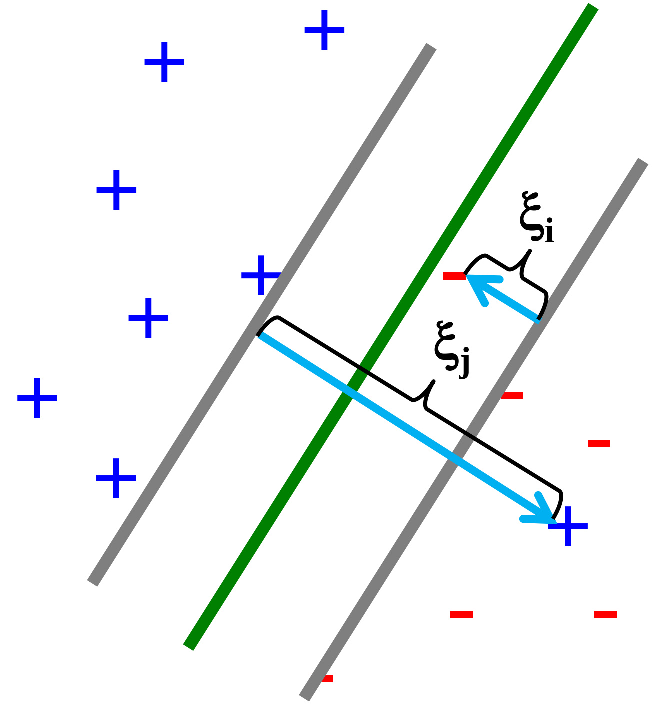

- Nicht alle falschen Zuordnungen sind gleich wichtig
- Bestrafung ξ_i

$$\min_{\boldsymbol{w}} \sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{w}_{\mathbf{i}}^{2} + \boldsymbol{C} \cdot \sum_{j} \xi_j$$

- *Hinge Loss* für Datenpunkt $(\boldsymbol{x}_i, y_i)$:

$$\xi_j := \max\left(0{,}1 - y_j\left(w_0 + \sum_{i=1}^{n} w_i\, x_{ji}\right)\right)$$

  - $\xi_j = 0$ falls x_j auf "richtiger Seite" der Ränder
  - $\xi_j \leq 1$ falls x_j auf "richtiger Seite" der Hyperebene
  - $\xi_j > 1$ falls x_j auf "falschen Seite" der Hyperebene

Support Vector Classifier

- **Zielfunktion**:

$$\min_{\boldsymbol{w}} \sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{w}_{\mathbf{i}}^{\mathbf{2}} + \boldsymbol{C} \cdot \sum_{j} \max\left(0{,}1 - y_j\left(w_0 + \sum_{i=1}^{n} w_i\, x_{ji}\right)\right)$$

- Schätzung der Parameter: (Stochastic) Gradient Descent

- Als ***Support-Vektoren*** bezeichnet man die Punkte des Datensatzes, welche direkt auf den Rändern oder auf der falschen Seite des zugehörigen Randes liegen → nur Support-Vektoren beeinflussen die Klassifizierung neuer Datenpunkte
- Sei S die Menge der Support-Vektoren und $\alpha_s \in \mathbb{R}$, $s \in S$, dazugehörige Parameter. Der Klassifizierer lässt sich in folgender Form schreiben:

$$f(x) = w_0 + \sum_{s \in S} \alpha_s\, (x \cdot x_s)$$

Support Vector Machine

- Erweiterung des (linearen) Support Vector Classifier über *Kernel:*

$$f(x) = w_0 + \sum_{s \in S} \alpha_s \, K(x, x_s)$$

Polynomial Kernel

$$K(x, x_s) = (1 + x \cdot x_s)^d$$

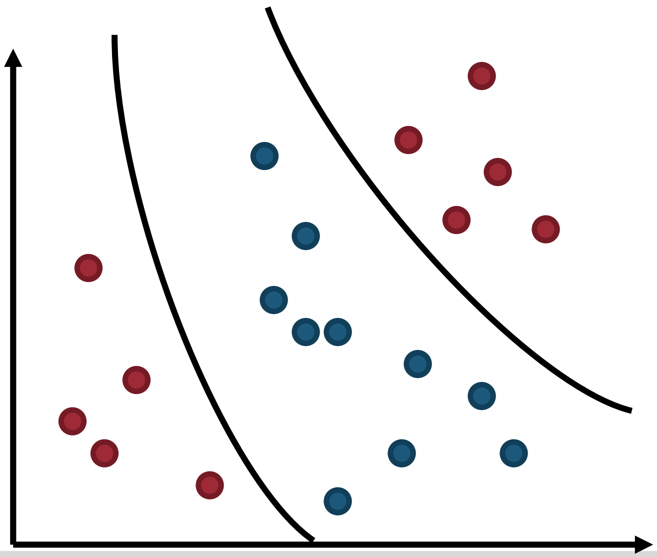

Radial Kernel

$$K(x, x_s) = \exp\left(-r \sum_{i=1}^{n} (x_i - x_{si})^2\right)$$

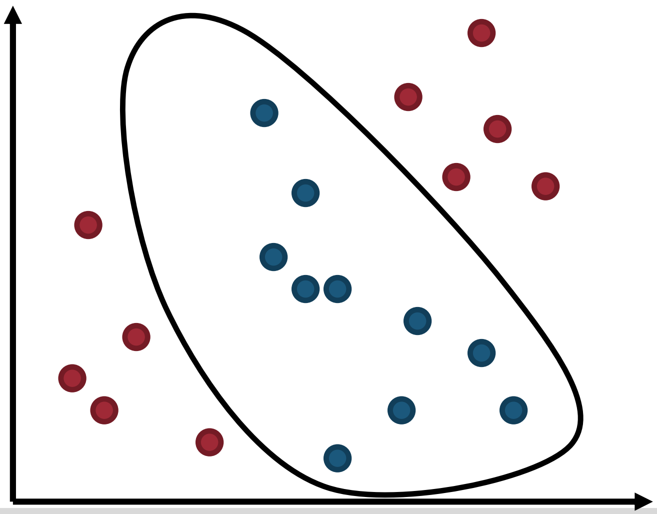

Vergleich

Support Vector Machines	Entscheidungsbäume
Klassifikation: gewöhnlich 2 Klassen (erweiterbar auf mehrere Klassen)	Regression & Klassifikation (mehrere (~10) Klassen)
Attribute sind numerisch bzw. binär	Attribute sind numerisch oder kategorial
Verwendung tausender, spärlich besetzter Attribute	Beschränkung auf wenige, dicht besetzte Attribute
Schwer interpretierbar	Gut interpretierbar
Beispiele: • Textklassifikation (Genre, Sentiment Analysis, Spamfilter) • Gesichtserkennung	Beispiele: • Kundenklassifikation (Segmentierung) • Operations Research (Entscheidungen in Unternehmen)

Inhaltsverzeichnis

- Einführung
- Entscheidungsbäume
- Support Vector Machines
- Neuronale Netze

Neuron (Perzeptron)

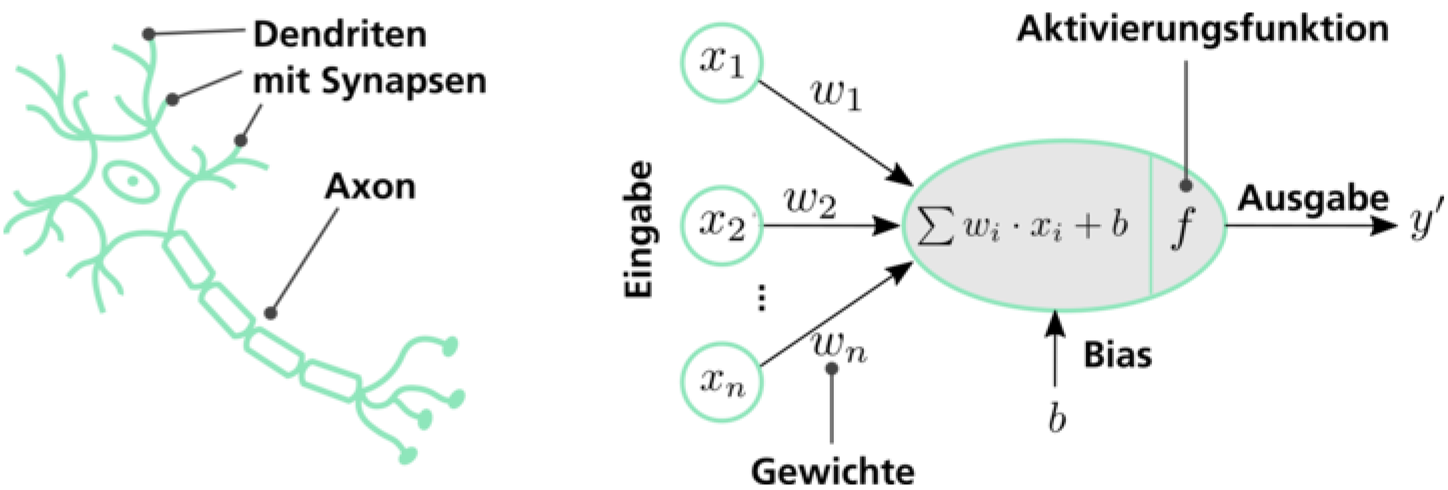

Quelle: https://www.informatik-aktuell.de/betrieb/kuenstliche-intelligenz/neuronale-netze-ein-blick-in-die-black-box.html

Neuronale Netze

Neuronale Netze bestehen aus, in Schichten angeordnete, Knoten, wobei die Ausgabe einer Schicht die Eingabe der nächsten Schicht darstellt

- Eingabeschicht
- Mehrere versteckte Schichten
- Ausgabeschicht

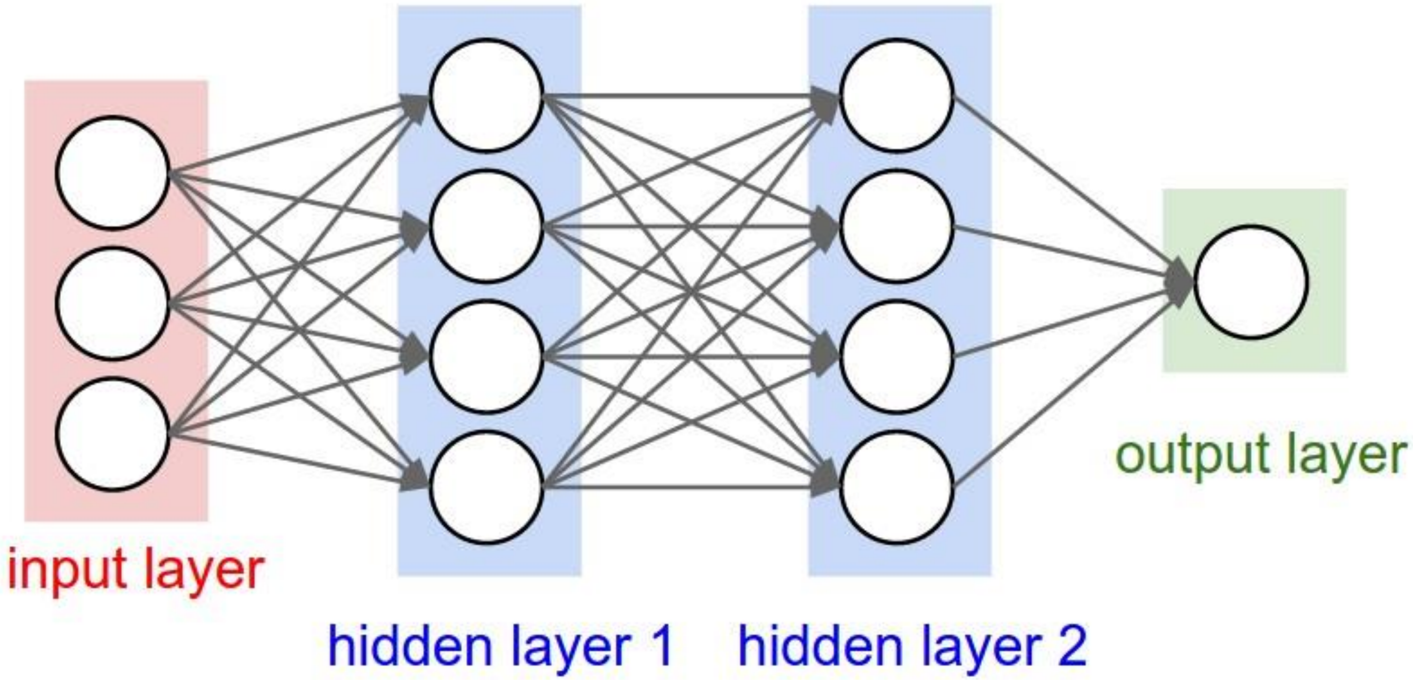

Quelle: http://cs231n.github.io/neural-networks-1/

Aktivierungsfunktion

- Lernen der Gewichte über **Gradient Descent**
- Gute Funktionen für Gradient Descent:
  1. Stetig und (fast überall) differenzierbar
  2. Ableitung wird nicht zu klein (über dem erwarteten Wertebereich)
  3. Ableitung wird nicht zu groß (über dem erwarteten Wertebereich)

z

Aktivierungsfunktionen

Sigmoid

$$\sigma(x) = \frac{e^x}{1 + e^x}$$

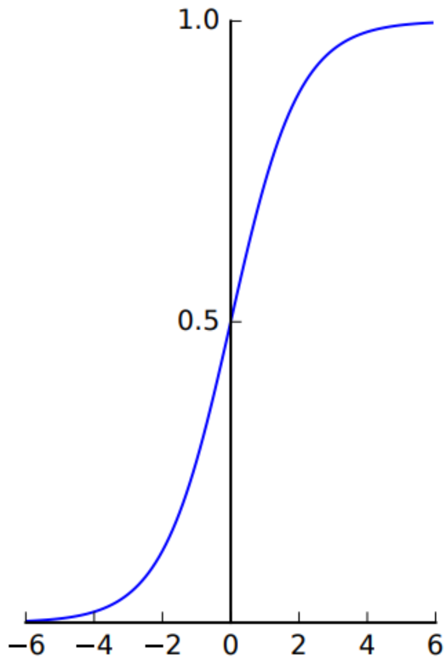

Hyperbolic Tangent

$$tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

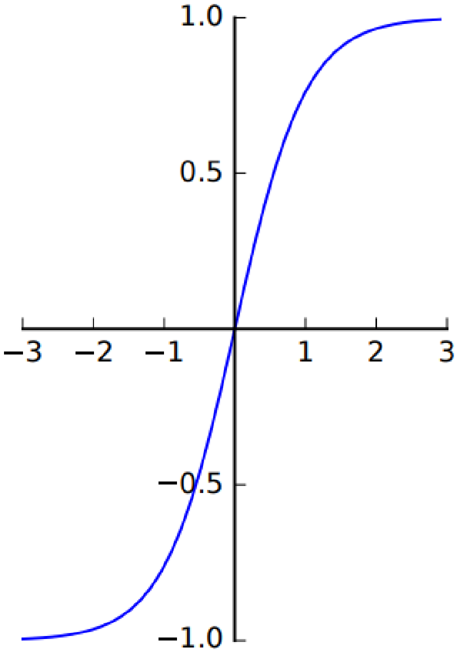

Aktivierungsfunktionen

ReLU (Rectified Linear Unit)

$$f(x) = \max(0, x)$$

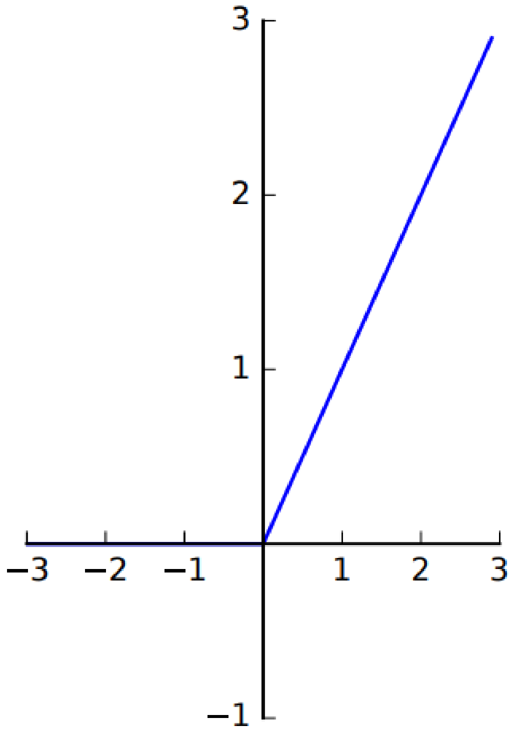

ELU (Exponential Linear Unit)

$$f(x) = \begin{cases} x & , x \geq 0 \\ \alpha(e^x - 1) & , x < 0 \end{cases}$$

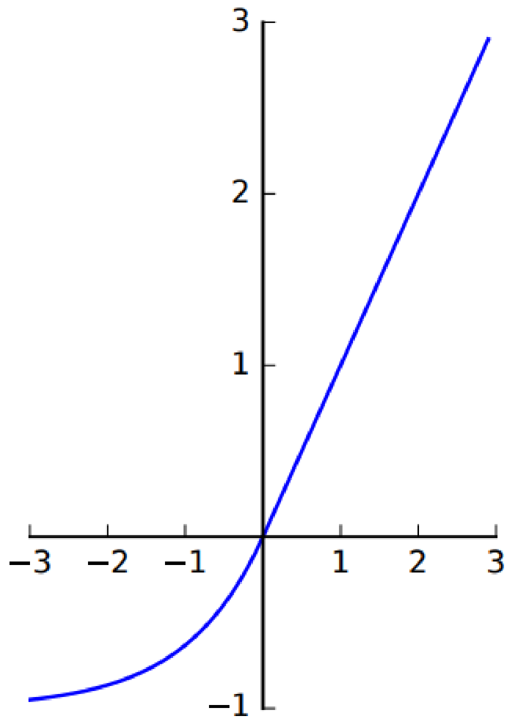

Kostenfunktion zur Bewertung der Ergebnisse

- Variable Y: numerisch (Regression)
- Sei N die Anzahl der Datenpunkte, y_j die tatsächlichen Bezeichnungen und $\hat{y}_j$ die, durch das Neuronale Netz vorhergesagten, Bezeichnungen
- **Mean Squared Error:**

$$MSE = \frac{1}{N}\sum_{j=1}^{N}\left(y_j - \hat{y}_j\right)^2$$

- *Gradient*

$$\nabla_{\hat{y}_j} MSE = \frac{\partial MSE}{\partial \hat{y}_j} = \frac{1}{N} 2\left(\hat{y}_j - y_j\right)$$

Optimierungsalgorithmus zum Lernen der Gewichte

- Anpassung der Gewichte (w_{ij} und u_j) mit dem Ziel der Minimierung der Kostenfunktion
- Effizientes Verfahren: **Gradient Descent** mit **Backpropagation**

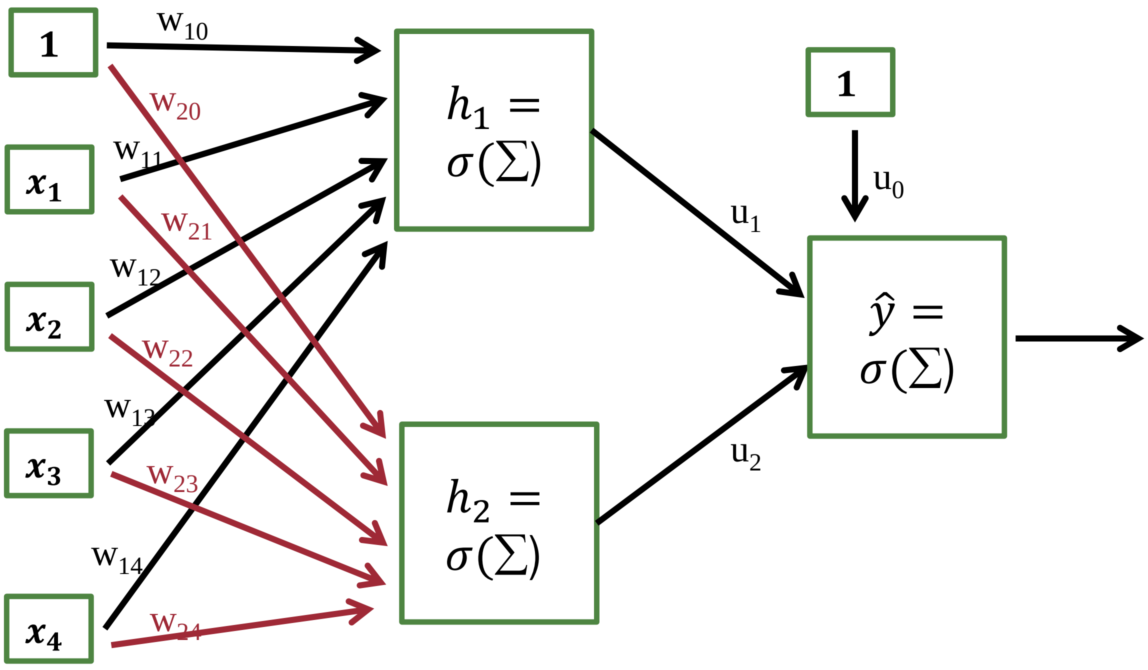

Backpropagation: Algorithmus

- 1. [Forwardpropagation]: Die Eingabewerte x_i laufen vorwärts durch das Netz und an jedem Neuron j wird mit Hilfe der Aktivierungsfunktion φ das Aktivierungslevel $\hat{a}_j$ berechnet.
- 2. [Backpropagation]:

  a) Für jedes Neuron j wird der Fehler δ_j berechnet:

  - Falls Neuron j in der Ausgabeschicht liegt: $\delta_j = \varphi'\left(net_j\right) * (\hat{y}_j - y_j)$
  - Falls Neuron j ein Hidden Neuron ist: $\delta_j = \varphi'\left(net_j\right) * \sum_k(\delta_k * w_{jk})$

    (dabei läuft k über alle Neuron j nachgeschalteten Neuronen)

  Dabei ist die Netzeingabe net_j definiert durch $net_j = \sum_{i=1}^{n} x_i w_{ij}$

  b) Berechnung der Gewichtsänderung: $\Delta w_{jk} = \eta * \delta_k * \hat{a}_j$

  (mit η als Lernrate)
- 3. Wiederhole Schritte 1 und 2 bis der Ausgangsfehler kleiner als ein gegebener Wert ist

Backpropagation: Beispiel (I)

- Sigmoid Aktivierungsfunktion $\varphi(x) = \frac{e^x}{1+e^x} = \frac{1}{1+e^{-x}}$
- Ableitung: $\varphi'(x) = \varphi(x) * (1 - \varphi(x))$
- Fehler δ_j
  - Ausgabeneuron: $\delta_j = \hat{y}_j * (1 - \hat{y}_j) * (y_j - \hat{y}_j)$
  - Hidden Neuron: $\delta_j = \hat{a}_j * (1 - \hat{a}_j) * \sum_k (\delta_k * w_{jk})$

Backpropagation: Beispiel (II)

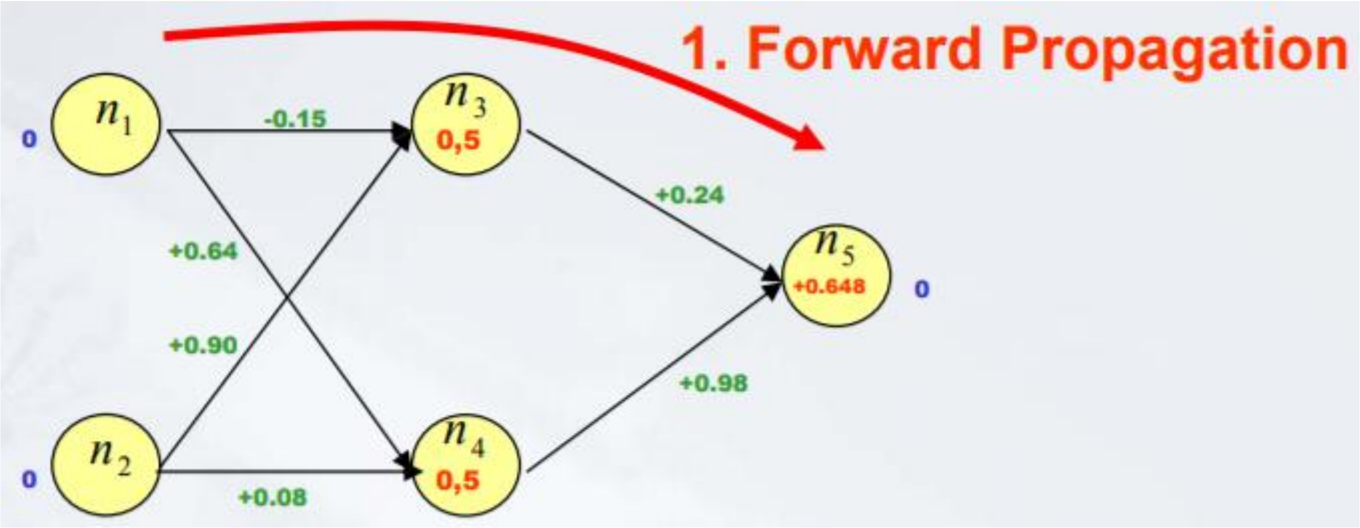

- $\delta_{n_5} = \hat{y}_{n_5} * (1 - \hat{y}_{n_5}) * (y_{n_5} - \hat{y}_{n_5})$=0.648∗(1−0.648)∗(0−0.648)=-0.148
- $\delta_{n_4} = \hat{a}_{n_4} * (1 - \hat{a}_{n_4}) * (\delta_{n_5} * w_{n_4 n_5})$=0.5∗(1−0.5)∗(−0.148∗0.98)=-0.036
- $\delta_{n_3} = \hat{a}_{n_3} * (1 - \hat{a}_{n_3}) * (\delta_{n_5} * w_{n_3 n_5})$=0.5∗(1−0.5)∗(−0.148∗0.24)=-0.009

Backpropagation: Beispiel (III)

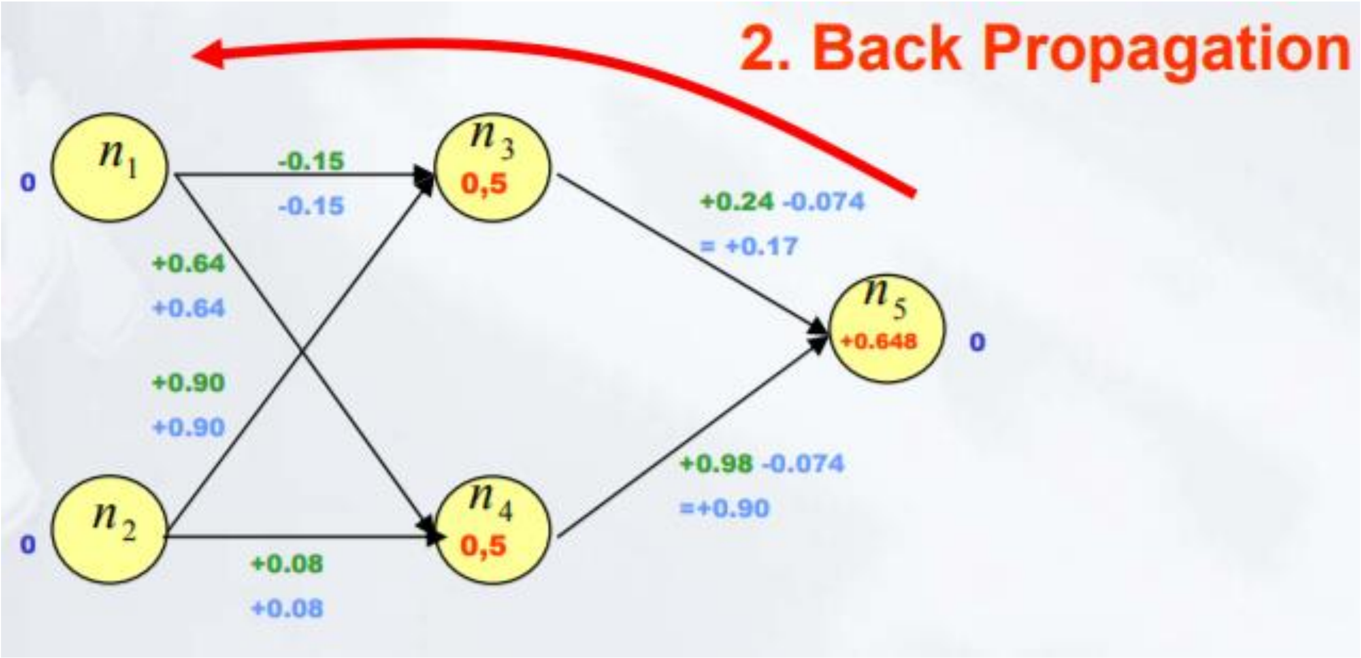

$\Delta w_{n_4 n_5} = \eta * \delta_{n_5} * \hat{a}_{n_4} = 1 * (-0.148) * 0.5 = -0.074$

Neuer Wert für $w_{n_4 n_5} = 0.98 - 0.074 = 0.90$

Convolutional Neural Networks (CNN)

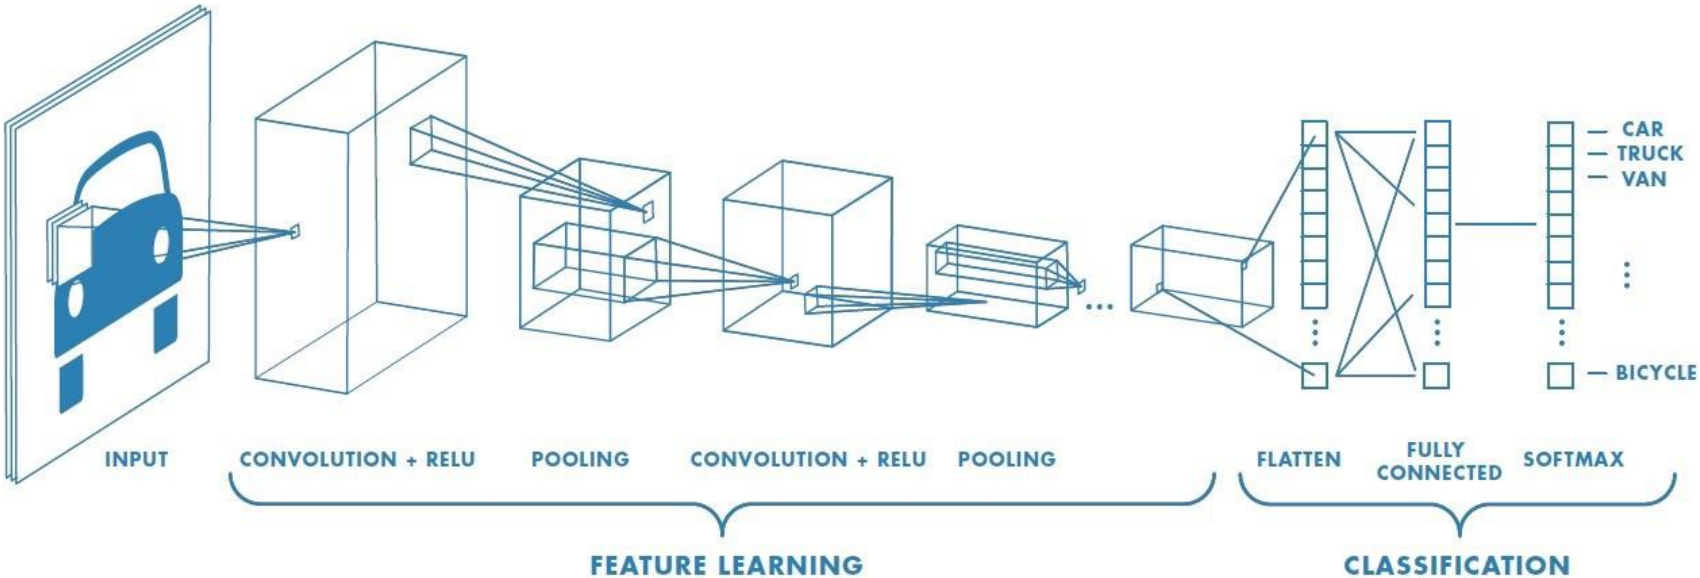

Quelle: https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53

Convolutional Layer

- **Filter** = Einteilung einer Schicht in Partitionen und Zuordnung jeder Partition zu nur einem Knoten der folgenden Schicht
- Faltungsmatrix (Filterkernel) wird über die Eingabe bewegt.
- Filter verwendet die selben Gewichte für jede Partition
- Mehrere Filter pro Schicht

Convolutional Neural Networks (CNN)

- Filter für 2-dimensionale Eingabe:

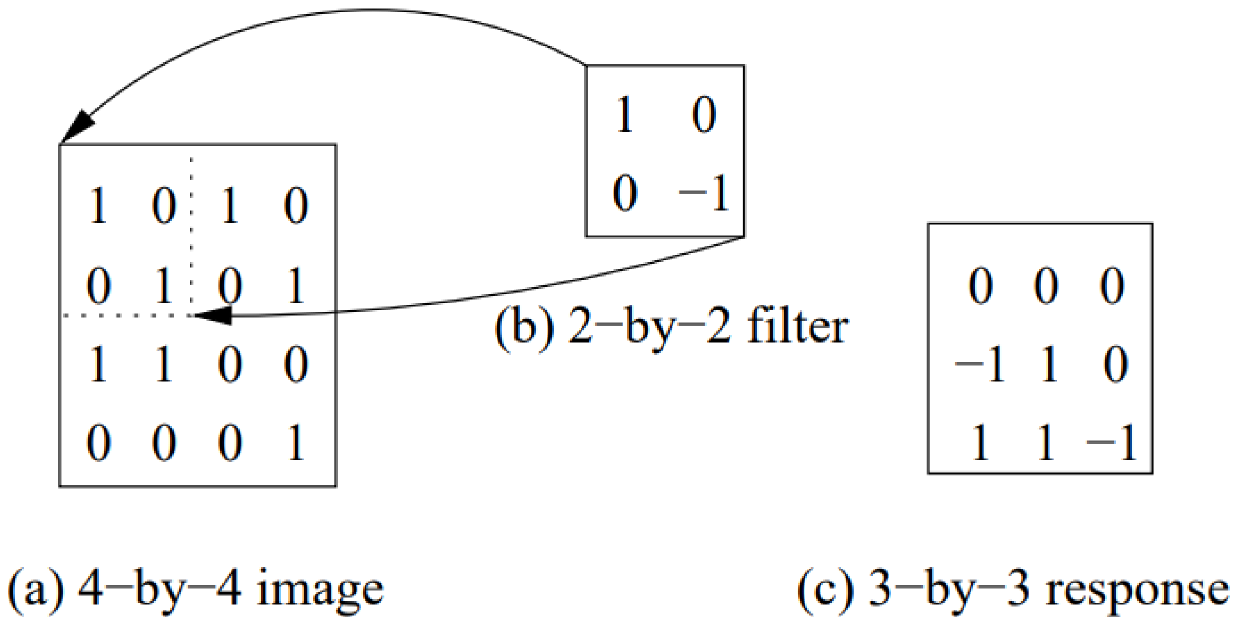

- CNN eignen sich besonders für die Verarbeitung für Bildern
- Filter der ersten versteckten Schicht können darauf trainiert werden bestimmte einfache Formen zu erkennen, z.B. eine Ecke/Gerade
- Nachfolgende (Convolutional) Schichten können diese dann zu komplexeren Formen zusammensetzen, z.B. ein Kopf, eine Ampel,…

CNN: Beispiel

Erkennen handgeschriebener Zahlen

Quelle: https://en.wikipedia.org/wiki/MNIST_database

CNN: Beispiel

Erkennen von Kleidung (Bildsegmentierung)

Quelle: https://towardsdatascience.com/stuart-weitzman-boots-designer-bags-and-outfits-with-mask-r-cnn-92a267a02819

CNN: Beispiel

Erkennen von frei werdenden Parkplätzen / Zählung von Menschen

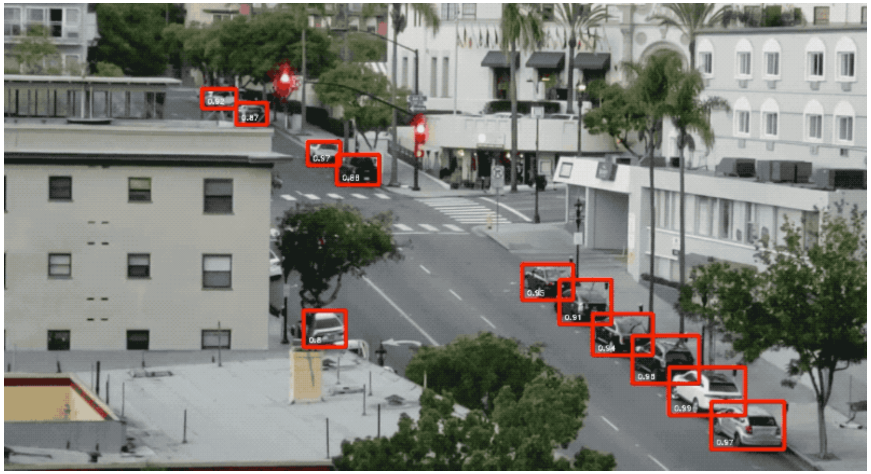

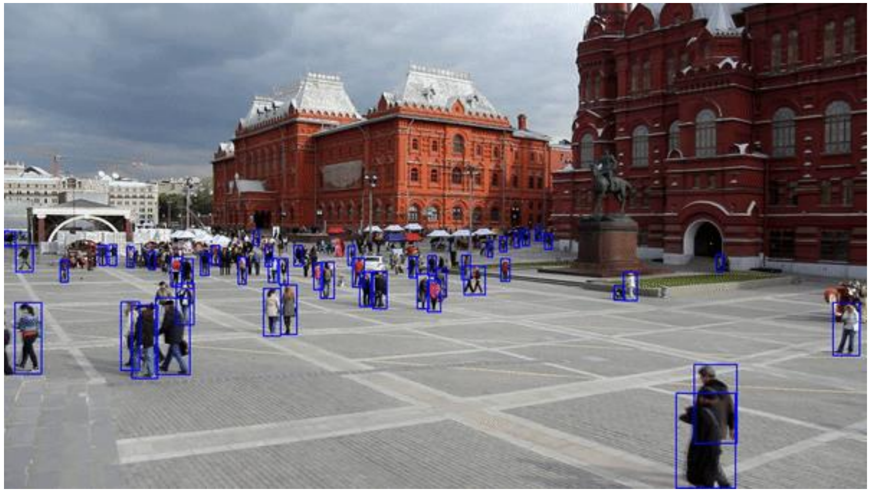

Quellen:

- https://medium.com/@ageitgey/snagging-parking-spaces-with-mask-r-cnn-and-python-955f2231c400
- https://nanonets.com/blog/crowd-counting-review/?utm_source=reddit&utm_medium=social&utm_campaign=drcrco&utm_content=dl

Recurrent Neural Networks (RNN)

- Spezielle Netzwerke für Verarbeitung von Sequenzen, z.B.
  - Text (Sequenz aus Wörtern)
  - Videos (Sequenz aus Bilder)
- Beispiel: Text
  - Eingabe $x = (x_1, \ldots, x_n)$ bezeichnet ein Wort (One-Hot Encoded: Dimension n ist die Anzahl der möglichen Wörter; genau eine Eins an der Stelle des Wortes, ansonsten nur Nullen)
  - Beachtung der Reihenfolge der Wörter über zyklische Verbindung innerhalb einer Schicht
  - Zyklische Schicht kann sich Zustände „merken“ und beeinflusst die Verarbeitung des nächsten Wortes

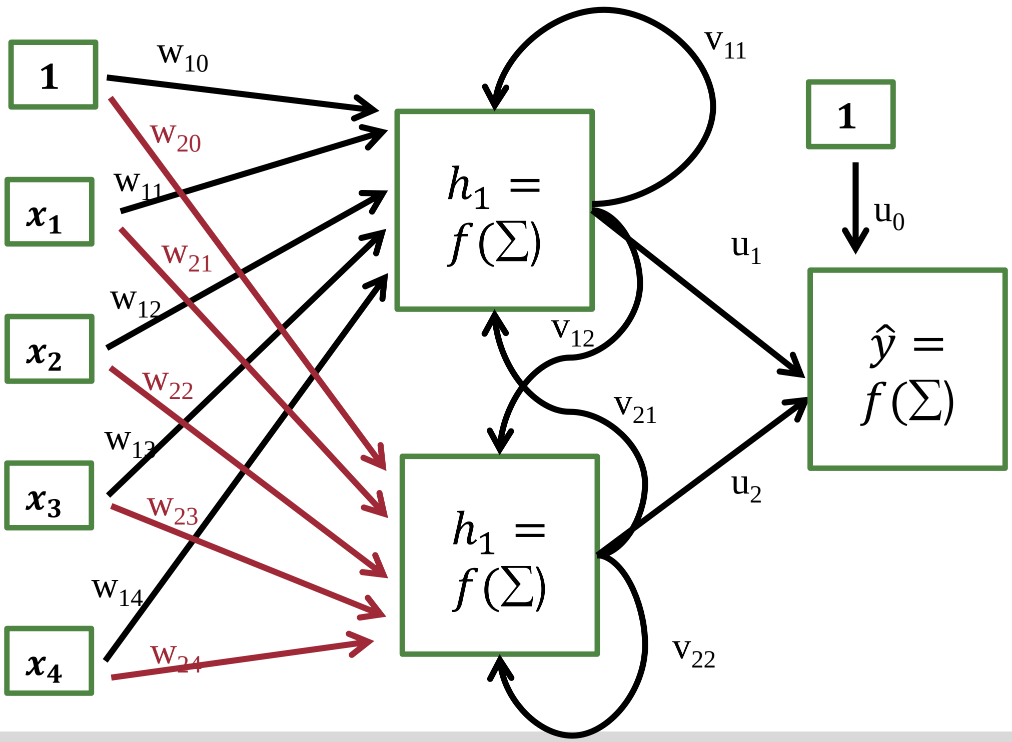

RNN: Beispiel

- Klassifizierung von Texten
- Positive oder negative Rezensionen

```
> sample_predict('The movie was cool. The animation and the graphics were out of this world. I would recommend this movie.')
[[0.4186573]]
```

```
> sample_predict('The movie was not good. The animation and the graphics were terrible. I would not recommend this movie.')
[[0.05746633]]
```

Quelle: https://www.tensorflow.org/tutorials/text/text_classification_rnn

RNN: Beispiel

- Maschinelle Übersetzung
- 2 hintereinander geschaltete RNN:

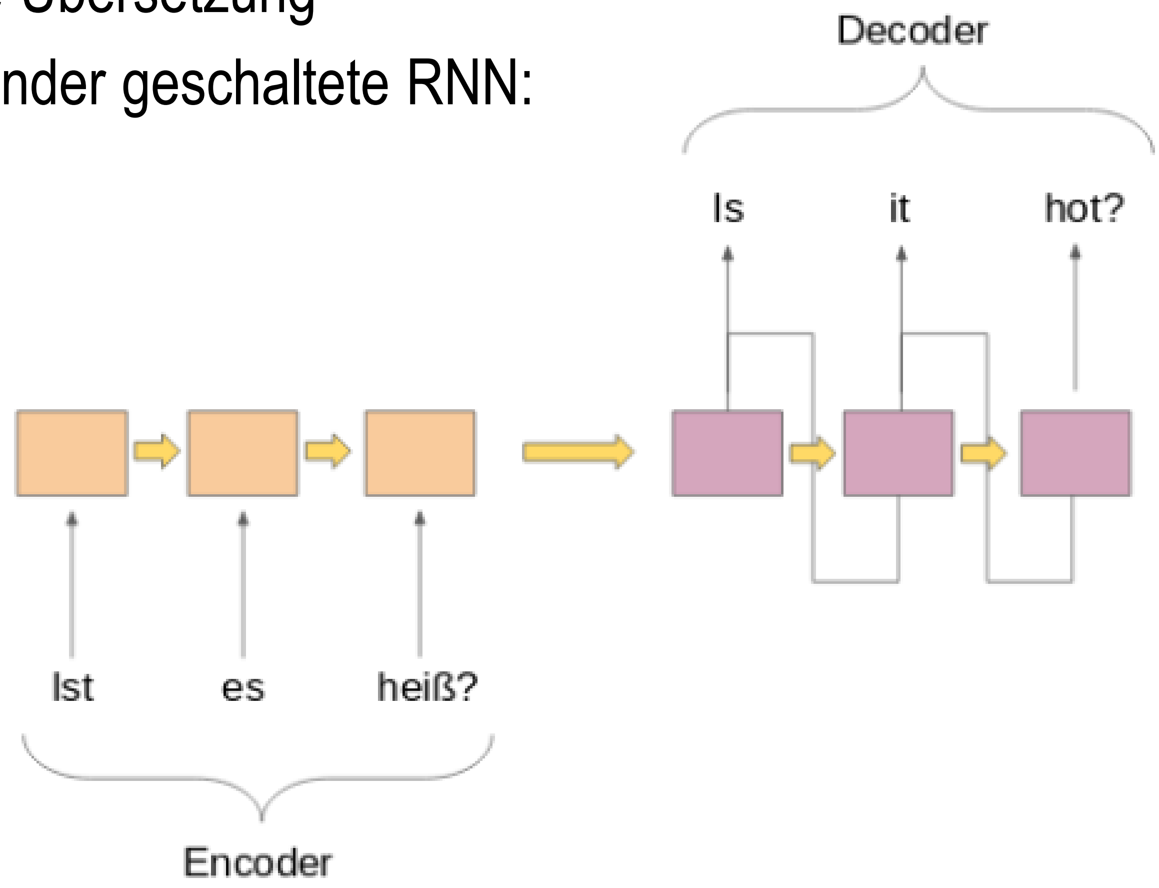

Quelle: https://medium.com/analytics-vidhya/a-must-read-nlp-tutorial-on-neural-machine-translation-the-technique-powering-google-translate-c5c8d97d7587

RNN: Beispiel

- Textgenerierung: z.B. Gedichte
- Eingabe des Nutzers: Thema oder Bild

Mountains

A hundred thousand Morrison formation,
An ancient crown of gold or mountain chains,
Mountains from the land of elevation,
A northern storm across the hills and plains.

the sun is a beautiful thing
in silence is drawn
between the trees
only the beginning of light

Quellen:

- http://xingshi.me/data/pdf/ACL2017demo.pdf
- https://arxiv.org/pdf/1804.08473.pdf